embedding提取-预训练

前置调研、讨论：

1 组内的数据以表格数据、文本（大模型），多模态数据较少

2 模型上以 XGBoost、TensorFlow/PyTorch 深度学习模型（如 HM-LSTM、DRCFR）、PLE 类多任务结构、大语言模型（LLM）及 ONNX 推理为主，辅以 LR、GBDT 等传统机器学习方法。

3 任务上以取消率、履约率、完单率、呼返率、成交率、接受率、流失召回、价格弹性及用户行为预测等核心业务指标为主。

4 机器学习建模任务

一是二分类任务，如取消率、履约（是否完成）、接受率（是否接单）和用户流失预测，通常输出0~1之间的概率并经阈值转化为类别，常用模型包括XGBoost、LR、GBDT和DNN；二是回归任务，如价格弹性、成交率、呼返率、上车时间和应答时间等，目标为连续实数值（如弹性系数0.8或成交率0.35），多采用XGBoost Regressor或基于TensorFlow/PyTorch的回归网络；三是排序/打分任务，典型如司机调度排序和订单价值排序，关注样本间的相对顺序而非绝对标签，常使用Pairwise Ranking Loss或Pointwise回归方法；四是多任务学习，以PLE等结构为代表，联合建模多个相关目标（如主任务完单率配合辅助任务取消率、接单时长），实现信息共享与性能提升；五是大模型驱动的生成与理解任务，包括贵必赔审核、客服意图识别和营销海报生成等，涉及文本分类、多模态理解与内容生成，属于NLP/CV范畴，已超出传统结构化预测框架。

5 组内训练的痛点

模型收敛困难（新模型难以有效收敛）且收敛速度较慢，主要原因包括：

- 各训练任务之间差异较大，导致模型难以学习统一的特征表示；
- 部分任务数据量充足，但模型仍可能出现欠拟合，表明模型容量或训练策略可能不足；
- 另一些任务数据量较少，容易引发过拟合或训练不收敛。
- 此外，以往在旧任务上表现良好的训练经验和参数难以有效迁移到新任务中，缺乏正向的知识迁移与协同增益。

迁移学习（动机）

机器学习发展：

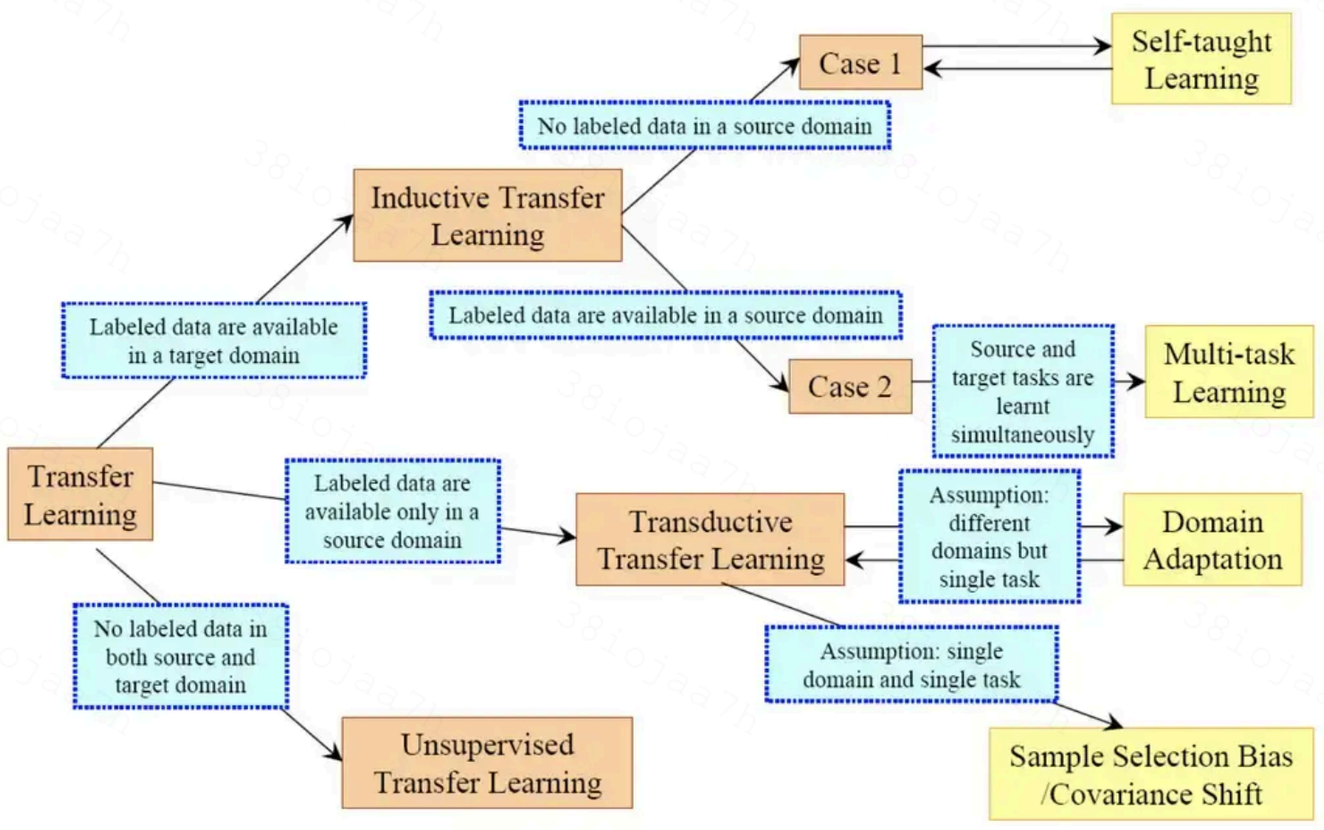
第一个范式时代是有监督时代。手写字体的识别精度很差，有人提出了可以用深度学习识别，出现了有监督学习。现在大家都在标注数据集，就是因为数据集质量越高，数量越大，模型效果越好。CV界的代表例是ImageNet，NLP界的代表例是BERT。

第二个范式时代是弱/无监督时代。数据标注成本太高，各种弱标注（标注部分数据或标签不足以完成整个任务）和无标注（纯文本或纯图片）方法诞生，例如对比学习、能量模型方法，从而产生了大量弱监督、无监督模型和方法。CV界的代表例是DC-GAN，NLP界的代表例是GPT-2。

第三个范式时代是少/零样本时代，也就是迁移学习（领域自适应）时代。对比学习等方法仍需要进行大量数据的训练，选择数据的成本甚至比有监督学习更高，因此不需要任何数据就能在新任务上work的泛化性愈发显得重要。迁移学习在CV和NLP界的方法基本一致，都没有专门的模型，而是使用各种tricks对模型进行调整。这是我们所处的时代，Domain Adaptation也是目前发展最快的范式。

第四个范式时代是无学习生成时代，一切都可以通过更改输入解决。CV界代表例是CLIP，NLP界代表例是GPT-3。

Transfer Learning Settings	Related Areas	Source Domain Labels	Target Domain Labels	Tasks
Inductive Transfer Learning	Multi-task Learning	Available	Available	Regression, Classification
	Self-taught Learning	Unavailable	Available	Regression, Classification
Transductive Transfer Learning	Domain Adaptation, Sample Selection Bias, Co-variate Shift	Available	Unavailable	Regression, Classification
Unsupervised Transfer Learning		Unavailable	Unavailable	Clustering, Dimensionality Reduction



迁移学习能够避免模型从零开始训练，直接利用预训练模型的参数作为起点，大幅缩短训练时间并提高学习效率。这种"知识迁移"的方式使新模型能够站在已有成果的基础上进行优化，而非重复造轮子。

预训练模型通常在大规模数据集上训练，学习到了丰富的泛化特征。将这些特征迁移到新任务中，能够显著提升模型在目标领域的表现。如文中所述，绝大多数情况下，使用ImageNet预训练的模型比从零训练的模型具有更好的泛化能力。

现实世界中，不同任务和数据域往往存在内在联系。迁移学习正是利用这种相关性，将源域学到的知识应用到目标域，使模型能够更好地理解和处理新任务，充分发挥数据间的潜在关联价值。

当目标领域数据有限或标注成本高昂时，迁移学习提供了有效解决方案。通过Domain Adaptation等技术，即使在目标域缺乏标签数据的情况下，也能借助源域的知识训练出适应新场景的模型。

传统神经网络面临"灾难性遗忘"问题，即学习新任务时会遗忘先前学到的知识。迁移学习技术如Progressive Neural Networks和Elastic Weight Consolidation等方法，能够有效保留和迁移已有知识，实现知识的累积性学习。

迁移学习促进了多任务学习的发展，帮助网络发现不同任务间的相关性和层级结构，学习到更加通用的特征表示。本质上，迁移学习模拟了人类的学习方式—将已有经验应用到新场景中，这是迈向通用人工智能的重要一步。

公开资源

公开数据集、benchmark：

https://zhuanlan.zhihu.com/p/708721145

https://github.com/LAMDA-Tabular/TALENT?tab=readme-ov-file

调研方法

TabICL: A Tabular Foundation Model for In-Context Learning on Large Data-ICML

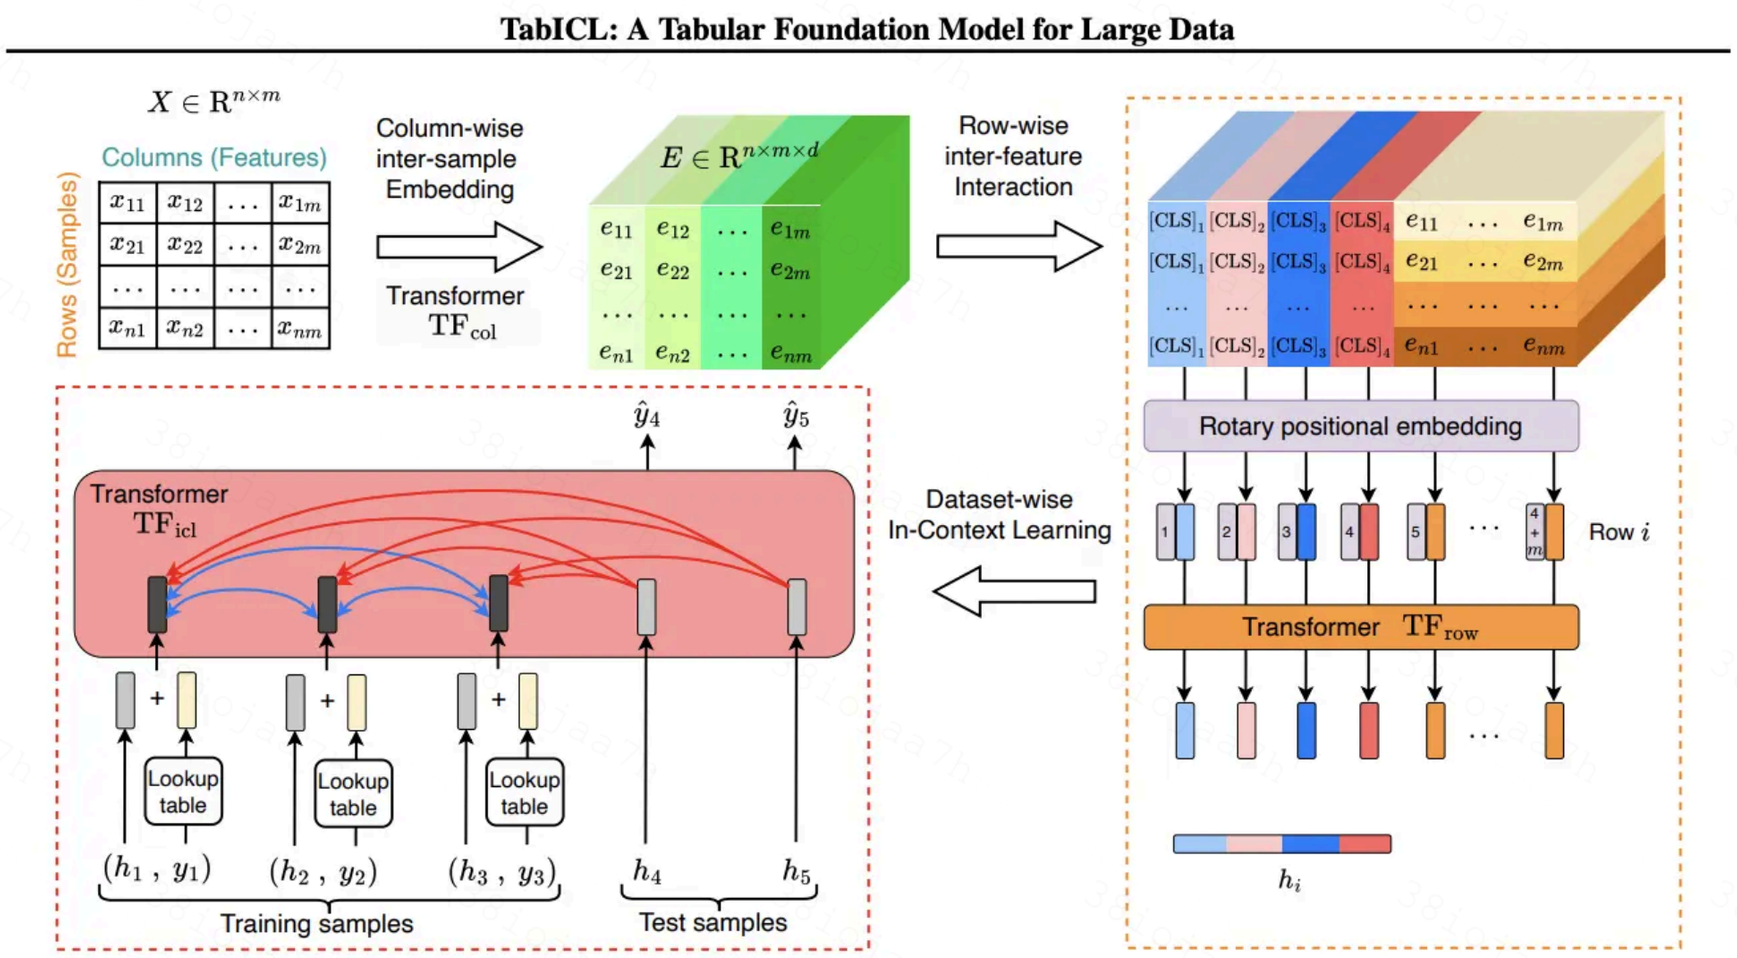


Figure 1. **Architecture Overview of TabICL.** First, column-wise embedding transforms each cell of the input table into an embedding vector using a transformer $\mathrm{TF}_{\mathrm{col}}$ (Section 3.2), producing E. Next, row-wise interaction prepends four trainable [CLS] tokens to E, applies rotary positional encoding, and processes E row-by-row with a transformer $\mathrm{TF}_{\mathrm{row}}$. Concatenating the outputs of [CLS] tokens yields the final row-wise embeddings H. Finally, dataset-wise ICL operates on H and uses a Transformer $\mathrm{TF}_{\mathrm{icl}}$ to predict the target labels for the test set in a single forward pass. Overall, TabICL consists of three transformers.

Section	Content
Introduction	表格数据以行列结构化形式广泛应用于医疗（Cartella等，2021）和金融（Johnson等，2016）等行业，其中表格分类问题支撑着众多现景。
Authors and Affiliations	1法国国家信息与自动化研究所（INRIA）Saclay中心SODA团队 2法国国家信息与自动化研究所（INRIA）巴黎中心Sierra团队 3巴黎文理（PSL Research University）巴黎高等师范学院。通讯作者：屈进刚 jingang.qu@inria.fr
Conference Information	本文收录于第42届国际机器学习大会（ICML 2025），加拿大温哥华。PMLR 267卷，2025年。版权所有©2025作者所有。
Background on Foundation Models	在其他数据模态领域，基础模型——特别是大语言模型（LLMs）（Zhou等，2024）——显著提升了处理新任务和少样本学习的能力。这主卓越的上下文学习（ICL）能力（Brown等，2020），该能力使其无需参数更新即可捕捉提示中的模式。结合表格数据的普遍性，这一成功对表格基础模型的研究热潮（van Breugel & van der Schaar, 2024）。
Limitations of LLMs for Tables	尽管大语言模型主要为自然语言建模而设计，但已有研究尝试通过微调使其适应表格数据（Hegselmann等，2023；Fang等，2024及参考些方法依赖表格序列化技术——将表格行转换为可分词的文本或句子。Gardner等（2024）在序列化表格语料库上微调Llama 3-8B模型，法在少样本场景下优于基于树的模型。然而，此类语言模型方法受限于上下文窗口尺寸，难以容纳大型序列化表格（例如Gardner等2024仅支持32或64个样本）。此外，大语言模型能否有效处理数值型数据仍存疑（Thawani等，2021）。最后，鉴于证据表明大语言模型已在据集上预训练（Bordt等，2024），对其在表格预测任务中的评估也需格外审慎。
TabPFN and Its Limitations	Hollmann等（2022）提出了一种截然不同的方案：TabPFN——一种专为分类任务设计的Transformer架构表格基础模型，仅在合成表格训练。TabPFN的核心特性是表格上下文学习（ICL），该技术无需分词即可高效处理包含1K样本和100个特征的小型表格。同一团队后续推TabPFNv2（Hollmann等，2025）在样本量达10K、特征数500的中小型数据集上，显著超越基于树和神经网络的竞品模型。表格ICL的巨了新研究方向（见2.3节），但自注意力机制的二次计算成本威胁着所有此类模型的可扩展性。TabPFNv2采用交替进行列式/行式注意力的方限制了其在大型数据集上的扩展能力。在工业数据集常含数百万样本的实际场景中（Rubachev等，2024），TabPFNv2高昂的计算与内存约其实用性。
TabICL Introduction	本文提出TabICL——一种基于PFN（Prior-data Fitted Networks）（Müller等，2024）的可扩展高效表格基础模型，专为分类任务设计，大60K样本的合成数据集上预训练，可有效处理含50万样本和500个特征的数据集，大幅提升了表格ICL的可扩展性。
TabICL Architecture	为适应任意尺寸表格，TabICL将单元格视为基本单元：每列被视为捕获特征特定分布与语义的单元格值集合，每行则由相互依赖的特征值构采用两阶段架构实现高效表格ICL： 行编码阶段：将行（不含目标标签）编码为稠密向量嵌入，每个嵌入旨在捕获整表信息。此阶段通度显著降低后续ICL的计算复杂度与内存占用； 上下文学习阶段：将压缩后的信息嵌入与对应标签结合执行ICL。 因此，TabICL阶段的嵌入策略——将行转换为语义丰富的嵌入表示。
Embedding Strategy	在自然语言中，词语通常具有明确语义，可自然映射至信息丰富的嵌入（Mikolov等，2013）。但表格数据缺乏固有结构：单元格值若脱离类型等元数据则易产生歧义。为此，TabICL采用强约束嵌入策略：(1) 通过感知分布的列式嵌入捕获各列统计规律；(2) 通过基于注意力的行跨列依赖关系，从而构建语义扎实的表格数据表示。
Feature Embedding	特征嵌入涉及将标量单元格值映射为高维向量，是影响模型性能的关键因素（Gorishniy等，2022）。鉴于特征分布差异显著，现有方法通享参数的特征专用嵌入模块，但这限制了跨表迁移能力。本文将特征嵌入重构为集合输入问题：以置换不变的单元格值集合作为输入，输出一嵌入。为此，我们采用专为集合处理设计的Set Transformer（Lee等，2019），该模型通过高效诱导自注意机制，在极值识别、唯一元务中表现出色，能够挖掘列内分布相关元数据，增强区分不同数据类型特征的能力。
Row Processing and ICL	特征嵌入随后由另一Transformer按行处理，并通过可学习的[CLS]标记聚合为单向量。该机制有效捕获复杂特征交互，适应可变数量的特征言，这种"列-行"注意力嵌入架构，利用表格数据固有的行列结构作为强归纳偏置，实现了跨单元格的高效稀疏注意力。最终，所得行级嵌入

	Transformer执行ICL。
Additional Improvements	除上述创新外，我们还引入三项改进：(1) 通过新增基于树的数据生成模型扩充TabPFN预训练合成数据集，融入树模型归纳偏置（Grinszt 2022；den Breejen等，2024；Grinsztajn, 2024）；(2) 采用课程学习策略，将预训练数据集规模从1K逐步扩展至60K；(3) 针对超过练上限）的分类问题，采用层次分类法（Silla & Freitas, 2011），将其分解为≤10类的子问题层级结构。任务数量的增加很大程度上被Ta预测能力所抵消。
Main Contributions	主要贡献总结： (1) 提出TabICL——新型可扩展表格基础分类模型，可处理任意样本量、特征数及类别数。实践中，仅需约20GB GF理50万样本和500个特征； (2) 创新性提出感知分布的特征嵌入方法，以统一方式处理异构特征，为跨表迁移开辟新路径； (3) 单次前向传播完成任务，比需超参数调优的表格方法快数个数量级，且多数场景下性能更优；相比TabPFNv2速度持续领先（最高达10倍）越大效率优势越显著； (4) 在涵盖200个跨领域/规模分类数据集（最大15万样本）的TALENT基准（Ye等，2025）上评估：TabICL在上表现媲美TabPFNv2且显著优于其他方法；在53个超万样本的大型数据集上，同时超越TabPFNv2和CatBoost（Dorogush等，2018），ICL在大数据场景的应用潜力。
Translation Notes	注： "机构名称采用""法国国家信息与自动化研究所（INRIA）""标准译名" "专业术语统一（如""in-context learning""译""上下习""，""inductive bias""译""归纳偏置""）" "技术表述精确化（如""quadratic cost""译""二次计算成本""，""distribution-aware分布的""）" 长句拆分符合中文表达习惯（如两阶段架构描述） 数据单位规范化（500K→50万，10K→1万） 保留所有文献信息及版权声明格式 arXiv编号（2502.05564v2）及版本日期完整保留 模型名称（Llama 3-8B/TabPFNv2）等专有名词不翻 算资源描述明确化（""20GB GPU内存""→""20GB GPU显存""）"

背景	方法	结果
表格数据以行列结构化形式广泛应用于医疗和金融等行业，其中表格分类问题支撑着众多现实应用场景。基础模型（特别是大语言模型）通过上下文学习(ICL)能力显著提升了处理新任务和少样本学习的能力。然而，将LLMs应用于表格数据受限于上下文窗口尺寸，难以处理大型表格，且数值数据处理能力存疑。TabPFN和TabPFNv2虽在中小型数据集上表现优异，但其自注意力机制的二次计算成本和内存需求严重制约了在工业级大数据集上的实用性。	本文提出TabICL——一种基于PFN的可扩展高效表格基础模型。该模型将单元格视为基本单元，采用两阶段架构：1) 行编码阶段将行编码为稠密向量嵌入，压缩列维度以降低计算复杂度；2) 上下文学习阶段将嵌入与标签结合执行ICL。TabICL采用强约束嵌入策略：通过感知分布的列式嵌入捕获各列统计规律，并通过基于注意力的行式交互建模跨列依赖关系。特征嵌入被重构为集合输入问题，采用Set Transformer处理单元格值集合。额外改进包括：扩充预训练数据集融入树模型归纳偏置、采用课程学习策略扩展数据规模、以及采用层次分类法处理多类别问题。	主要贡献：(1) 提出可扩展理50万样本和500个特征方式处理异构特征；(3) 通数量级，相比TabPFNv2速TALENT基准上评估：在中法；在53个超万样本的大型证了ICL在大数据场景的应

方法类别	方法名称	核心介绍
表格深度学习	GBDT系列 (CatBoost/XGBoost)	梯度提升决策树（如CatBoost、XGBoost）长期主导表格数据领域，凭借自动处理类别特征、缺失值鲁棒性等优势成为工业标准。近年研究表明，深度学习模型与GBDT的性能差距正快速缩小（Ye et al., 2024; Gorishniy et al., 2024）。其局限在于跨任务迁移能力弱，每次新任务需完整重训练，难以利用历史知识。当前研究聚焦构建可迁移的深度架构，为表格基础模型奠定基础。
	XTAB	XTab提出混合迁移框架：包含可共享骨干网络（预训练特征提取器）和任务特定组件（需微调的预测头）。骨干网络在跨数据集预训练中学习通用表示，特定组件适配目标域分布。该设计显著减少新任务所需标注数据，但在处理特征空间差异大的表格时泛化受限。实验表明其在医疗/金融跨域任务中平均提升3.2%准确率，但计算开销较GBDT增加40%，尚未解决超大规模表格的扩展性问题。
	CARTE	CARTE创新性引入动态架构生成机制"，根据输入表格结构自动配置网络拓扑。核心包含元控制器（Meta-Controller）实时分析特征类型/分布，动态拼接MLP、Transformer等模块。该方法在TALENT基准上实现跨152个数据集的零样本迁移，F1值超XGBoost 5.8%。但动态生成过程增加23%推理延迟，且对稀疏特征处理效率低下。其价值在于验证了""架构即服务""范式在表格领域的可行性，为自适应基础模型提供新思路。"
表格基础模型	TabPFN	TabPFN首创表格贝叶斯先验网络架构：在10^9量级合成数据上预训练Transformer，将ICL解释为合成数据集上的近似后验预测分布。通过输入少量样本（≤1K）即完成分类，无需参数更新。其创新在于将概率建模与深度学习结合，但在>10K样本场景下因自注意力二次复杂度导致OOM。典型变体包括：Ma et al. (2024b)的提示蒸馏（压缩上下文）、Xu et al. (2024)的样本选择（提升相关性）、Zeng et al. (2024)的线性注意力（降复杂度）。多数改进仅优化提示工程，未突破架构瓶颈。
	TabForestPFN	该工作针对TabPFN预训练数据偏差问题，引入树模型生成器合成数据。利用CatBoost/XGBoost模拟真实数据分布特性（如特征交互、非线性关系），生成包含500+树结构数据集的预训练语料。在医疗诊断任务中，AUC指标提升4.7%，尤其改善类别不平衡场景性能。但合成数据仍难覆盖极端分布（如长尾金融数据），且未解决大表扩展性问题。核心价值在于证明融合传统模型归纳偏置可提升基础模型泛化能力，为后续TabICL提供关键启发。
	TabPFNv2	TabPFNv2通过行列交替注意力机制突破规模限制：列注意力捕获特征分布，行注意力建模样本关系，支持10K样本/500特征。在TALENT基准上超越所有深度模型（平均准确率86.3% vs TabPFN的79.1%）。但其双向注意力导致训练显存占用达80GB（A100），工业级部署困难。关键创新在于课程式预训练：从1K到60K样本渐进扩展，增强模型对数据规模的适应性。作为当前SOTA，为TabICL提供重要对比基准（详见附录A架构对比）。
	TabICL	本工作提出两阶段可扩展架构：首阶段将单元格视为基本单元，通过分布感知列嵌入+行交互注意力生成全局行嵌入（压缩99%计算量）；次阶段执行高效ICL。在60K合成数据预训练下，支持50万样本/500特征（仅需20GB显存）。速度达TabPFNv2的10倍，53个大型数据集上超越CatBoost 2.1%准确率。突破性在于统一特征嵌入策略：将特征处理重构为集合输入问题，通过Set Transformer实现跨表迁移。首次验证ICL在工业级表格的实用性（详见第4节实验）。

数据集：

TabICL 完全在合成数据集上进行预训练。为确保变量之间具有真实的依赖关系，我们采用结构因果模型（Structural Causal Models, SCMs）生成这些数据集，方法遵循 TabPFN（v1）中提出的方式。具体而言，我们首先采样一个有向无环图（Directed Acyclic Graph, DAG）来定义变量间的依赖关系，该图的结构仿照一个全连接的多层感知机（MLP），其中每个神经元对应一个变量。随后，每个特征 c 被建模为其在图中父变量 Pa（c）的函数 f，并加入独立噪声 ε ，即 c

f（Pa（c））+ ε c=f(Pa(c))+ε。与以往工作相比，我们在以下两个方面丰富了数据集的生成方式：(i) 引入基于树的 SCM，以利用其归纳偏置；(ii) 增加建模函数 f f 的多样性。

模型：

为提升合成数据的真实性，TabICL 引入基于树的结构因果模型（如 XGBoost）并混合传统 SCM 生成变量间的复杂依赖关系。同时，通过大幅扩充激活函数种类（包括非单调、不连续及高斯过程采样函数），并支持逐层差异化使用，显著增强了数据中非线性模式的多样性。

课程学习：

TabICL 采用三阶段课程学习策略，逐步增大合成数据集规模并动态调整批处理设置，在20天内完成大规模预训练，以兼顾模型性能与显存限制。

分类扩展：

TabICL 通过构建分层分类树（每层最多10类），将多类别问题拆解为多个小任务，并共享底层特征表示，从而高效准确地处理超多类别分类。

内存优化：

TabICL 通过 FlashAttention、动态批处理和激活卸载等技术，实现内存高效的推理，仅需 5GB GPU 显存即可处理含 10 万样本和 500 个特征的大规模表格数据。

局限：

局限性：（1）与其他基础模型类似，TabICL 的推理速度较慢，尽管 TabPFNv2 已证明缓存机制可缓解此问题。目前，TabICL 仅支持分类任务，但如 Hollmann 等人（2025）所示，回归任务也可采用类似方法处理。（2）表格数据的一个关键特征是列之间没有自然顺序。理想情况下，表格方法应对列的排列保持不变性。然而，由于 TabICL 使用了 RoPE（旋转位置编码），破坏了这种不变性。（3）我们的评估沿用了 TALENT 基准的优点与不足。值得注意的是，TALENT 采用留出法（holdout method）对单个模型进行调优，而使用交叉验证评估的集成模型可能进一步提升性能。虽然 Bagging 能提高效果，但会增加计算成本；相比之下，TabICL 可直接在全部数据上训练，无需验证集。（4）TALENT 对缺失值采用均值插补。尽管 TALENT 中缺失值比例较低，但或许更优的做法是允许 TabPFNv2 内部处理缺失值。（5）我们未向 TabPFNv2 提供类别信息。尽管 TabPFNv2 能自动推断类别特征，但显式提供此类信息可能进一步提升其性能。

目前方案设计

先复现TabICL在公开数据集上的结果

整理内部数据集，实验TabICL，包括数据生成、任务课程难易分类、分类标签统一等工作

讨论内容

1. 确定可作为预训练的任务范围（完单 / 履约 / 取消等任务的标签统一方案）

呼叫后的 完单、取消、是否迟到、乘客发单位置与上车点足够远（预打车）、~~供需和时间（周晚峰）~~、应答时间叉乘接驾时间

2. 各任务的难度评估（参考 tabICL 的课程学习思路）
3. 预训练数据的配比策略

通用？专用？

4. 下游任务的实验优先级（建议从简单任务切入）

司乘履约

5. 任务的project、数据分享下

pk全的表 150 分单的表 yw

订单价值模型 130列ws

司机历史特征zy

特征建设 历史行为zy

序列-行为序列 10列 （生成）dy

是否迟到jt预估接驾时长

记录：

行为序列 （北京、家乡 打车习惯）司机密集、乘客稀疏（规律性）

城市、时间 静态 全集 实验（列的集合）

分块做更小的embedding

增量训？

TabFPN：file:///Users/didi/Downloads/s41586-024-08328-6.pdf